

Neuralne mreže

Projektni zadatak

Vladimir Grijaković 2022/0183

Konstantin Simjanović 2022/0013

Projektovanje potpuno konvolucione mreže

Postavka zadatka

Potrebno je projektovati konvolucionu neuralnu mrežu (CNN) za klasifikaciju slika u više klasa. Skup podataka koji će se koristiti studenti pronalaze samostalno, pri čemu je važno da sadrži dovoljno slika raspoređenih u više jasno definisanih klasa.

Potrebno je opisati prirodu problema koji se rešava (tip ulaznih podataka, broj i naziv klasa) i prikazati grafikon koji prikazuje broj uzoraka po klasama. Obrazložiti da li su podaci balansirani. U slučaju da klase nisu balansirane potrebno je primeniti neku od tehnika za rešavanje tog problema.

Zatim je potrebno izvršiti predprocesiranje podataka (npr. skaliranje, normalizaciju, augmentaciju, balansiranje itd.). Treba navesti koje su transformacije primenjene, sa obrazloženjem njihove svrhe i uticaja na model.

Na osnovu obrađenih podataka, potrebno je formirati i obučiti konvolucionu mrežu za klasifikaciju. Pri tome je potrebno obrazložiti izbor: kriterijumske funkcije, funkcije aktivacija neurona, kao i metode optimizacije korišćene za minimizaciju funkcije greške. Na kraju, potrebno je prikazati arhitekturu razvijenog modela (npr. u koristeći `model.summary()`), kao i navesti ukupan broj parametara u modelu. U slučaju primene već postojećih modela CNN potrebno je opisati taj model, koje su njegove prednosti i mane, i postupak primene prenosa znanja.


Primeniti neku od metoda zaštite od preobučavanja. Objasniti šta je preobučavanje neuralne mreže, kao i metodu koju ste primenili kao zaštitu.

Od rezultata prikazati i komentarisati:


- po jedan primerak iz svake klase,
- histogram raspodele odbiraka po klasama,
- grafik promena performansi tokom epoha treniranja,
- vrednosti performansi klasifikacije, kao što su: tačnost, preciznost, osetljivost, f1-skor,
- matricu konfuzije na trening i test skupu,
- primere dobro i loše klasifikovanih slika iz skupa podataka.

Rešenje

U pitanju je problem razlikovanja dronova i ptica, vec su odvojeni podaci za trening, validaciju i testiranje tako da ih nije bilo potrebno posebno izdvajati. Dakle postoje 2 klase - klasa drone i klasa bird broj odbiraka svake klase može se videti na sledećem histogramu:




Kao što se na histogramu vidi podaci nisu balansirani, odnosno utrening skupu ima više slika dronova nego ptica pa je upotrebljena metoda dodele težina klasama kako bi se CNN model istrenirao podjednako dobro za prepoznavanje obe klase. Težina svake klase je obrnuto proporcionalna broju odbiraka(slika) u tok klasi.



Što se predprocesiranja podataka tiče odradjena je augmentacija na ulazu, odnosno jedna ulazna slika je rotirana, flipovana, zumirana i menjani su joj osvetljenost i kontrast kako bi se mreža bolje naučila da prepoznaje dron ili pticu nezavisno od orijentacije i boje slike. Promena kontrasta i osvetljenosti je posebno značajno bilo za treniranje mreže jer je skoro svaki dron slikan na nebu ali ptica je mogla biti na nebu, zemlji, na drvetu ili u šumi pa se bez tog dela augmentacije mreža previše oslanjala na pozadinu, odnosno njenu boju i manje efikasno razvrstavala klase. Takodje, nakon augmentacije, pre ulaza u mrežu, ulazni podaci su skalirani u opseg od -1 do 1 koji je optimalan za MobileNetV2 mrežu koja je korišćena kao osnova.

Slike dobijene od jedne slike u sloju augmentacije:



Što se samog modela tiče, u početku je isprobavano da se napravi i obuči model od nule ali to nije davalo zadovoljavajuće rezultate pa je izabrana metoda transfera znanja a za osnovu modela izabran MobileNetV2 koji je nadogradjen i prilagodjen problemu koji se ovde rešava. MobileNet je vec obučena mreža sa milionima parametara i vrlo dobro prepoznaje različite ivice, oblike, boje, itd. pa je odlično odgovarao nešem problemu. Na njegovu osnovu smo dodali GlobalAveragePooling sloj, Dropout sloj i 3 gusto povezana sloja neurona, prva 2 koriste relu kao aktivacionu funkciju kako bi se unele nelinearnosti, a poslenji sloj koristi softmax kako bi na izlazu dala verovatnoće kojoj klasi pripada ulazna slika. Što se optimizacije tiče korišćen je Adam sa konstantom učenja 0.005, a funkcija gubitaka je SparseCategoricalCrossentropy jer su labela za klase 0 i 1, odnosno nije korišćeno hot one kodovanje.

Layer (type)	Output Shape	Param #
sequential (Sequential)	(None, 160, 160, 3)	0
lambda (Lambda)	(None, 160, 160, 3)	0
mobilenetv2_1.00_160 (Functional)	(None, 5, 5, 1280)	2,257,984
global_average_pooling2d (GlobalAveragePooling2D)	(None, 1280)	0
dropout (Dropout)	(None, 1280)	0
dense (Dense)	(None, 128)	163,968
dense_1 (Dense)	(None, 64)	8,256
dense_2 (Dense)	(None, 2)	130
Total params: 2,430,338 (9.27 MB)		
Trainable params: 172,354 (673.26 KB)		
Non-trainable params: 2,257,984 (8.61 MB)		

Kada je treniranje ovog modela u pitanju, kako ne bi došlo do preobučavanja, odnosno prevelike prilagodjenosti mreže podacima za treiranje i time slabije generalizacije, korišćene su metode ranog zaustavljanja i dropout sloja. Prate se performanse modela na osnovu validacionog skupa podataka i na osnovu toga odlučuje kada mreža prestaje sa obučavanjema a ujedno se i odredjeni postotak neurona gasi (nasumično) pre svake epohe kako bi mreža bila naterana da bolje generalizuje i više distribuira znanje preko cele mreže.


Treniranje se radi u 2 faze, prva je obučavanje mreže bez promene osnove modela odnosno sa već učitanim težinama u MobileNetV2 mreži i epohe tog treniranja izgledaju ovako:

```

Epoch 1/30
286/286 ————— 58s 196ms/step - accuracy: 0.9384 - loss: 0.1431 - val_accuracy: 0.7010 - val_loss: 0.7239
Epoch 2/30
286/286 ————— 57s 199ms/step - accuracy: 0.9840 - loss: 0.0449 - val_accuracy: 0.8480 - val_loss: 0.4008
Epoch 3/30
286/286 ————— 58s 202ms/step - accuracy: 0.9856 - loss: 0.0397 - val_accuracy: 0.6740 - val_loss: 0.8432
Epoch 4/30
286/286 ————— 59s 205ms/step - accuracy: 0.9904 - loss: 0.0274 - val_accuracy: 0.8230 - val_loss: 0.5328
Epoch 5/30
286/286 ————— 79s 272ms/step - accuracy: 0.9886 - loss: 0.0310 - val_accuracy: 0.7720 - val_loss: 0.6630
Epoch 6/30
286/286 ————— 188s 656ms/step - accuracy: 0.9890 - loss: 0.0305 - val_accuracy: 0.7500 - val_loss: 0.7606
Epoch 7/30
286/286 ————— 219s 762ms/step - accuracy: 0.9903 - loss: 0.0254 - val_accuracy: 0.8250 - val_loss: 0.4413

```

Takodje, ovde je i grafik promene performansi tokom treniranja:




Druga faza je fine-tuning - sada doobučavamo mrežu tako što dopuštamo da se u osnova modela promeni ali sa jako malom konstantom učenja, na taj način će se već naučena mreža MobileNetV2 malo prilagoditi problemu koji trenutno rešavamo i time dati bolje rezultate:

```


Epoch 1/15
286/286 ————— 888s 3s/step - accuracy: 0.9157 - loss: 0.1911 - val_accuracy: 0.9690 - val_loss: 0.1018
Epoch 2/15
286/286 ————— 893s 3s/step - accuracy: 0.9837 - loss: 0.0449 - val_accuracy: 0.9810 - val_loss: 0.0551
Epoch 3/15
286/286 ————— 863s 3s/step - accuracy: 0.9915 - loss: 0.0263 - val_accuracy: 0.9810 - val_loss: 0.0585
Epoch 4/15
286/286 ————— 865s 3s/step - accuracy: 0.9930 - loss: 0.0205 - val_accuracy: 0.9760 - val_loss: 0.0736
Epoch 5/15
286/286 ————— 863s 3s/step - accuracy: 0.9935 - loss: 0.0175 - val_accuracy: 0.9220 - val_loss: 0.1853
Epoch 6/15
286/286 ————— 863s 3s/step - accuracy: 0.9947 - loss: 0.0137 - val_accuracy: 0.8440 - val_loss: 0.3619
Epoch 7/15
286/286 ————— 867s 3s/step - accuracy: 0.9952 - loss: 0.0115 - val_accuracy: 0.8440 - val_loss: 0.3586
Epoch 7: early stopping
Restoring model weights from the end of the best epoch: 2.

```

Nakon obučavanja na red dolazi testiranje mreže i provera performansi. Na trening skupu matrica konfuzije izgleda ovako:



Skoro bez greške(tačnost 99.85%), a na test skupu, gde se stvarno vide performanse modela na podacima koje prvi put vidi:



Tačnost je 95.28%, što je dosta zadovoljavajuće. Kao što se vidi ptica je skoro bez greške klasifikovana kako treba ali za dronove se desi da ih greškom klasifikuje kao pticu. Performanse klasifikacije, pored tačnosti, na ovom trening skupu su:

```
Tačnost modela je: 95.28%
True Negative: 359
False Positive: 2
False Negative: 40
True Positive: 488
Tacnost: 0.9528
Preciznost: 0.9959
Osetljivost (Recall): 0.9242
Specifičnost: 0.9945
F1-skor: 0.9587
Balansirana tacnost: 0.9594
```